Introduction à l'exploration de données

IA, modèles, visualisation

Master Management de l'Innovation

Janvier 2026

Fouille de données textuelles

Qu'est-ce que l'analyse textuelle ?

Définition

L'analyse textuelle, ou NLP, consiste à traiter et explorer des textes pour en extraire des informations utiles et comprendre leur contenu.

C'est une extension du data mining à des corpus de textes

Qu'est-ce que l'analyse textuelle ?

Définition

L'analyse textuelle, ou NLP, consiste à traiter et explorer des textes pour en extraire des informations utiles et comprendre leur contenu.

C'est une extension du data mining à des corpus de textes

Pourquoi ?

Elle permet d'automatiser la compréhension des textes en identifiant des tendances, des sentiments, ou des thèmes.

Information utile ?

Quels sont les mots les plus représentés ?

Information utile ?

Quels sont les mots les plus représentés ?

Quels sont les sujets abordés ?

Information utile ?

Quels sont les mots les plus représentés ?

Quels sont les sujets abordés ?

Quels sont les concepts clés et les relations entre eux ?

Information utile ?

Quels sont les mots les plus représentés ?

Quels sont les sujets abordés ?

Quels sont les concepts clés et les relations entre eux ?

Quels sont les phrases ou les paragraphes spécifiques au sujet du texte ?

Information utile ?

Quels sont les mots les plus représentés ?

Quels sont les sujets abordés ?

Quels sont les concepts clés et les relations entre eux ?

Quels sont les phrases ou les paragraphes spécifiques au sujet du texte ?

Quelle est la structure logique d'un texte ?

Exemple 1 : fréquence des mots

Calcul du **nombre d'occurrence** de chaque mot dans un texte.

Correlation and variable importance in random forests

Baptiste Gregorutti (1) , Bertrand Michel (1) , Philippe Saint-Pierre (1)

Afficher plus de détails

1 **LSTA - Laboratoire de Statistique Théorique et Appliquée**

Résumé en

This paper is about variable selection with random forests algorithm in presence of correlated predictors. In high-dimensional regression or classification frameworks, variable selection is a difficult task, that becomes even more challenging in the presence of highly correlated predictors. Firstly we provide a theoretical study of the permutation importance measure for an additive regression model. This allows us to describe how the correlation between predictors impacts the permutation importance. Our results motivate the use of the Recursive Feature Elimination (RFE) algorithm for variable selection in this context. This algorithm recursively eliminates the variables using permutation importance measure as a ranking criterion. Next various simulation experiments illustrate the efficiency of the RFE algorithm for selecting a small number of variables together with a good prediction error. Finally, this selection algorithm is tested on a real life dataset from aviation safety where the flight data recorders are analysed for the prediction of a dangerous event.

Mot	Fréquence
Variable	5
Selection	4
Algorithm	3
Correlated	3
Predictors	2
Regression	2
Importance	2

Exemple 2 : mots clés

Extraction des **mots clés** → identifier les idées principales

Correlation and variable importance in random forests

Baptiste Gregorutti (1) , Bertrand Michel (1) , Philippe Saint-Pierre (1)

Afficher plus de détails

1 **LSTA - Laboratoire de Statistique Théorique et Appliquée**

Résumé en

This paper is about variable selection with random forests algorithm in presence of correlated predictors. In high-dimensional regression or classification frameworks, variable selection is a difficult task, that becomes even more challenging in the presence of highly correlated predictors. Firstly we provide a theoretical study of the permutation importance measure for an additive regression model. This allows us to describe how the correlation between predictors impacts the permutation importance. Our results motivate the use of the Recursive Feature Elimination (RFE) algorithm for variable selection in this context. This algorithm recursively eliminates the variables using permutation importance measure as a ranking criterion. Next various simulation experiments illustrate the efficiency of the RFE algorithm for selecting a small number of variables together with a good prediction error. Finally, this selection algorithm is tested on a real life dataset from aviation safety where the flight data recorders are analysed for the prediction of a dangerous event.

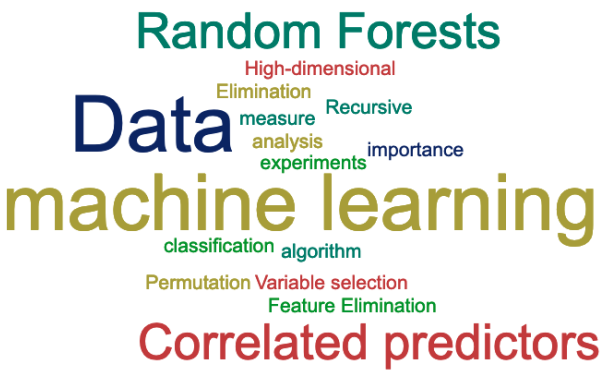

Exemple 3 : entités nommées

Extraction des **entités nommées** → identifier les personnes, lieux, organisations, dates, etc.

Agatha Christie

Article Discussion

Pour les articles homonymes, voir Christie.

Agatha Christie est une femme de lettres britannique, auteur de nombreux romans policiers, née le 15 septembre 1890 à Torquay et morte le 12 janvier 1976 à Wallingford au Royaume-Uni. Son nom de plume est associé à celui de ses deux héros : Hercule Poirot, détective professionnel belge, et Miss Marple, détective amateur. On surnomme Agatha Christie « la Reine du crime ». En effet, elle est l'un des écrivains les plus importants et novateurs du genre policier. Elle a aussi écrit plusieurs romans, dont quelques histoires sentimentales, sous le pseudonyme Mary Westmacott.

Agatha Christie fait partie des écrivains les plus connus au monde et elle est considérée comme l'auteur le plus lu de l'histoire chez les Anglo-Saxons, après William Shakespeare ; c'est aussi de très loin l'auteur le plus traduit dans le monde[2]. Elle a publié 66 romans, 154 nouvelles et 20 pièces de théâtre, ces œuvres ayant été traduites en plusieurs langues. La plupart des intrigues se déroulent à huis clos, ce qui permet au lecteur d'essayer de deviner l'identité du coupable avant la fin du récit. La saveur de ses histoires réside dans la résolution de l'enquête, souvent improbable, prenant le lecteur par surprise.

Ses romans et nouvelles ont été adaptés au cinéma, dans des jeux vidéo ou à la télévision, en particulier *Le Crime de l'Orient-Express*, *Dix Petits Nègres*, *Mort sur le Nil*, *Le Train de 16 h 50* et *Témoin à charge*.

Personnes : Agatha Christie, Hercule Poirot, Miss Marple, William Shakespeare

Lieux : Torquay, Wallingford, Royaume-Uni

Dates : 15 septembre 1890, 12 janvier 1976

Genres et styles : Roman policier, théâtre

Médias : Cinéma, jeux vidéo

Exemple 4 : analyse de sentiments

L'analyse de sentiments consiste à identifier le ton d'un texte

Agatha Christie

Article Discussion

Pour les articles homonymes, voir Christie.

Agatha Christie est une femme de lettres britannique, auteur de nombreux romans policiers, née le 15 septembre 1890 à Torquay et morte le 12 janvier 1976 à Wallingford au Royaume-Uni. Son nom de plume est associé à celui de ses deux héros : Hercule Poirot, détective professionnel belge, et Miss Marple, détective amateur. On surnomme Agatha Christie « la Reine du crime ». En effet, elle est l'un des écrivains les plus importants et novateurs du genre policier. Elle a aussi écrit plusieurs romans, dont quelques histoires sentimentales, sous le pseudonyme Mary Westmacott.

Agatha Christie fait partie des écrivains les plus connus au monde et elle est considérée comme l'auteur le plus lu de l'histoire chez les Anglo-Saxons, après William Shakespeare ; c'est aussi de très loin l'auteur le plus traduit dans le monde[2]. Elle a publié 66 romans, 154 nouvelles et 20 pièces de théâtre, ces œuvres ayant été traduites en plusieurs langues. La plupart des intrigues se déroulent à huis clos, ce qui permet au lecteur d'essayer de deviner l'identité du coupable avant la fin du récit. La saveur de ses histoires réside dans la résolution de l'enquête, souvent improbable, prenant le lecteur par surprise.

Ses romans et nouvelles ont été adaptés au cinéma, dans des jeux vidéo ou à la télévision, en particulier *Le Crime de l'Orient-Express*, *Dix Petits Nègres*, *Mort sur le Nil*, *Le Train de 16 h 50* et *Témoin à charge*.

Exemple 4 : analyse de sentiments

L'analyse de sentiments consiste à identifier le ton d'un texte

Peste noire

Article Discussion Lire M

Pour les articles homonymes, voir Peste noire (homonymie).

La **peste noire**, aussi appelée **grande peste** ou **mort noire**, est une pandémie de peste (principalement bubonique) qui a sévi au milieu du XIVe siècle (pendant le Moyen Âge).

Probablement originaire d'Asie centrale, la pandémie touche l'Europe à travers les invasions mongoles, puis se propage en Afrique du Nord voire en Afrique subsaharienne, faisant jusqu'à 200 millions de victimes à travers le monde. Il s'agit à la fois de la pandémie la plus meurtrière et de la plus grande catastrophe démographique enregistrée dans l'histoire de l'humanité.

En Europe, elle fait environ 25 millions de victimes en cinq ou six ans (1347-1352), soit entre 30 et 60 % de la population. Les conséquences sur la civilisation européenne sont sévères et longues, d'autant que cette première vague est considérée comme le début explosif et dévastateur de la deuxième pandémie de peste, qui dure de façon plus sporadique jusqu'au début du XIXe siècle.

Cette pandémie provoque indirectement la chute de la dynastie Yuan en Chine, affecte l'Empire khmer et affaiblit encore plus ce qui reste de l'Empire byzantin, en déclin depuis le début du XIVe siècle.

Son nom lui a été donné par les historiens modernes ; elle n'est ni la première ni la dernière pandémie de peste, mais c'est la seule à porter ce nom. C'est aussi la première pandémie à avoir été bien décrite par les chroniqueurs de l'époque.

Exemple 4 : analyse de sentiments

L'analyse de sentiments consiste à identifier le ton d'un texte

Correlation and variable importance in random forests

Baptiste Gregorutti (1) , Bertrand Michel (1) , Philippe Saint-Pierre (1)

Afficher plus de détails

1 **LSTA - Laboratoire de Statistique Théorique et Appliquée**

Résumé en

This paper is about variable selection with random forests algorithm in presence of correlated predictors. In high-dimensional regression or classification frameworks, variable selection is a difficult task, that becomes even more challenging in the presence of highly correlated predictors. Firstly we provide a theoretical study of the permutation importance measure for an additive regression model. This allows us to describe how the correlation between predictors impacts the permutation importance. Our results motivate the use of the Recursive Feature Elimination (RFE) algorithm for variable selection in this context. This algorithm recursively eliminates the variables using permutation importance measure as a ranking criterion. Next various simulation experiments illustrate the efficiency of the RFE algorithm for selecting a small number of variables together with a good prediction error. Finally, this selection algorithm is tested on a real life dataset from aviation safety where the flight data recorders are analysed for the prediction of a dangerous event.

Exemple 5 : segmentation de texte

Consiste à identifier la structure d'un document

arXiv:1310.5726v5 [stat.ME] 18 Apr 2016

Correlation and variable importance in random forests TITLE

Baptiste Gregorutti[12*], Bertrand Michel[2], Philippe Saint-Pierre[2] AUTHORS

[1] *Safety Line*
15 rue Jean-Baptiste Berlier, 75013 Paris, France

[2] *Laboratoire de Statistique Théorique et Appliquée*
Université Pierre et Marie Curie
4 place Jussieu, 75252 Paris Cedex 05, France

ABSTRACT

Abstract

This paper is about variable selection with the random forests algorithm in presence of correlated predictors. In high-dimensional regression or classification frameworks, variable selection is a difficult task, that becomes even more challenging in the presence of highly correlated predictors. Firstly we provide a theoretical study of the permutation importance measure for an additive regression model. This allows us to describe how the correlation between predictors impacts the permutation importance. Our results motivate the use of the Recursive Feature Elimination (RFE) algorithm for variable selection in this context. This algorithm recursively eliminates the variables using permutation importance measure as a ranking criterion. Next various simulation experiments illustrate the efficiency of the RFE algorithm for selecting a small number of variables together with a good prediction error. Finally, this selection algorithm is tested on the Landsat Satellite data from the UCI Machine Learning Repository.

Keywords: Random Forests, Supervised Learning, Variable Importance, Variable Selection.

KEYWORDS

1 Introduction SECTION

In large scale learning problems, in particular when the number of variables is much larger than the number of observations, not all of the variables are relevant for predicting the outcome of interest. Some irrelevant variables may have a negative effect on the model accuracy. Variable selection techniques, also called feature selection or subset selection, involve eliminating irrelevant variables and provide two main advantages. First, a model with a small number of variables is more interpretable. Secondly, the model accuracy might be improved and then avoid the risk of overfitting.

Many studies about variable selection have been conducted during the last decade. In Guyon and Elisseeff [14], the authors review three existing approaches: filter, embedded and wrapper. A filter algorithm, also known as variable ranking, orders the variables in a preprocessing step and the selection is done independently of the choice of the learning technique. Two classical ranking criteria are the Pearson correlation coefficient and the mutual information criterion as mentioned in the recent survey of Lazar et al. [23]. The main drawback of this approach

*Corresponding author: baptiste.gregorutti@safety-line.fr

PLAIN TEXT

Importance du contexte

Importance du contexte

La prise en compte du contexte est la capacité à **interpréter correctement le sens des mots ou des phrases**, et ainsi à améliorer la précision des analyses

Importance du contexte

Ambiguité lexicale (polysémie)

Un mot peut avoir plusieurs sens

Ex : bureau, affection, légende

Importance du contexte

Ambiguité lexicale (polysémie)

Un mot peut avoir plusieurs sens
Ex : bureau, affection, légende

Relations sémantiques

Le sens d'un mot peut être influencé par les mots qui l'entourent
Ex : banque de prêts vs banque d'organes

Importance du contexte

Ambiguité lexicale (polysémie)

Un mot peut avoir plusieurs sens
Ex : bureau, affection, légende

Relations sémantiques

Le sens d'un mot peut être influencé par les mots qui l'entourent
Ex : banque de prêts vs banque d'organes

Ambiguité dans les entités

Certaines entités nécessitent un contexte pour être correctement identifiées
Ex : Apple vs apple ou bien Paris vs paris

Importance du contexte

Ambiguité lexicale (polysémie)

Un mot peut avoir plusieurs sens
Ex : bureau, affection, légende

Relations sémantiques

Le sens d'un mot peut être influencé par les mots qui l'entourent
Ex : banque de prêts vs banque d'organes

Ambiguité dans les entités

Certaines entités nécessitent un contexte pour être correctement identifiées
Ex : Apple vs apple ou bien Paris vs paris

Compréhension du sens global

Les outils modernes ont besoin du contexte pour mieux comprendre le sens global d'une phrase

Quelques concepts techniques

Stop Words

Définition

Mots fréquents et peu significatifs dans une langue :
`"et"`, `"le"`, `"de"`, etc.

Objectif

Les exclure pour se concentrer sur le contenu pertinent.

Tokenization

Qu'est-ce qu'un token ?

- Un **mot**

  `"Bonjour. Comment ça va ?"` $\rightarrow$ `["Bonjour", "Comment", "ça", "va"]`

- Une **phrase**

  `"Bonjour. Comment ça va ?"` $\rightarrow$ `["Bonjour.", "Comment ça va ?"]`

- Un **sous-mot**

  `"impossible"` $\rightarrow$ `["im", "possible"]`

Objectif de la tokenization

Diviser un texte en **tokens** pour en faciliter l'analyse

Tokenization

Qu'est-ce qu'un token ?

- Un **mot**

  `"Bonjour.  Comment ça va ?"` $\rightarrow$ [1, 2, 3, 4]

- Une **phrase**

  `"Bonjour.  Comment ça va ?"` $\rightarrow$ [5, 6]

- Un **sous-mot**

  `"impossible"` $\rightarrow$ [7, 8]

Objectif de la tokenization

Diviser un texte en **tokens** pour en faciliter l'analyse

Lemmatisation

Qu'est-ce qu'un lemme ?

La forme canonique d'un mot.

Objectif de la lemmatisation

Réduire les mots à leur forme canonique
Ex : `mangeait` $\rightarrow$ `manger`

A ne pas confondre avec la racinisation (stemming)

Plongement lexical

Définition

Le plongement lexical, ou plongement sémantique, vise à représenter les mots sous forme de vecteurs.

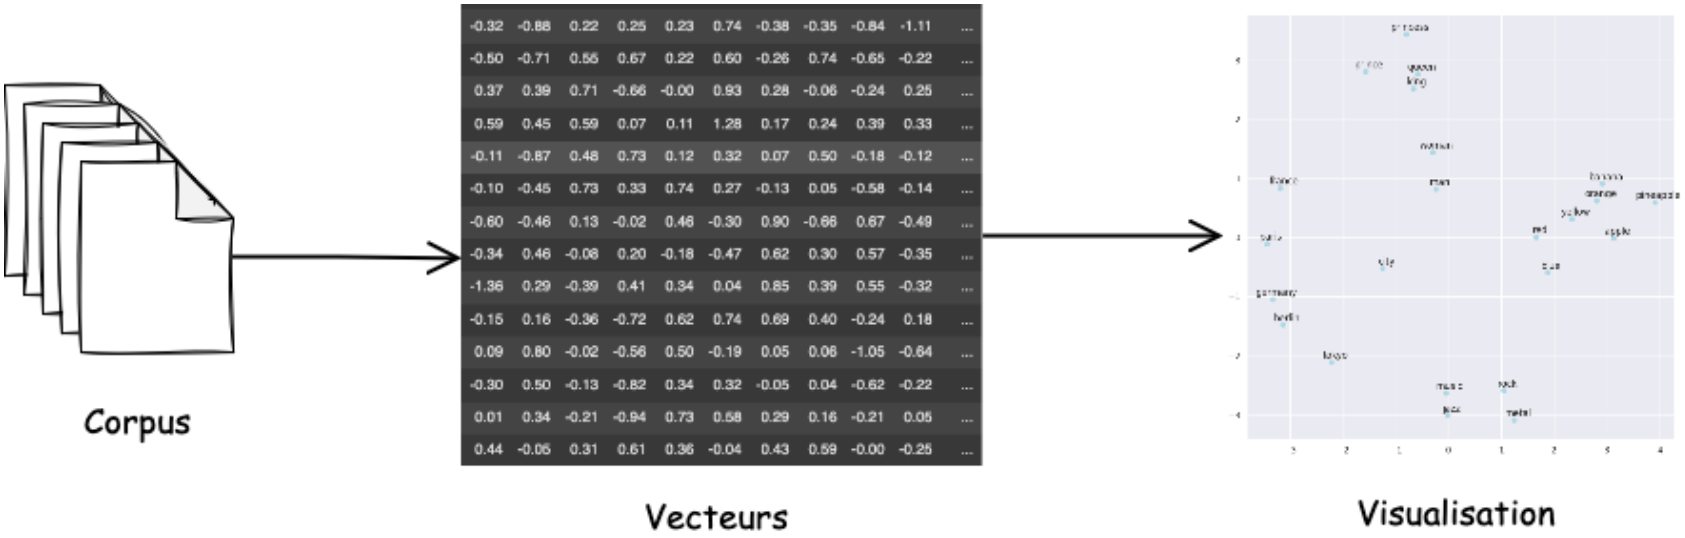

Plongement lexical

Définition

Le plongement lexical, ou plongement sémantique, vise à représenter les mots sous forme de vecteurs.

Pourquoi ?

Pour utiliser les outils statistiques (visualisation et modélisation) tout simplement !

Plongement lexical

Cas d'usage

Cas d'usage

Marketing

Marketing ciblé, publicité personnalisée, support client

Cas d'usage

Marketing

Marketing ciblé, publicité personnalisée, support client

Recherche historique

Analyse de corpus historique pour aider la recherche

Cas d'usage

Marketing

Marketing ciblé, publicité personnalisée, support client

Recherche historique

Analyse de corpus historique pour aider la recherche

Bases de données documentaires

Indexer, structurer une base de données et moteurs de recherche Classification de documents, dé-doublonnage

Apprentissage automatique

Apprentissage automatique

Un ensemble d'algorithmes permettant à une machine d'apprendre un phénomène à partir de données

Texte

Image
vidéo

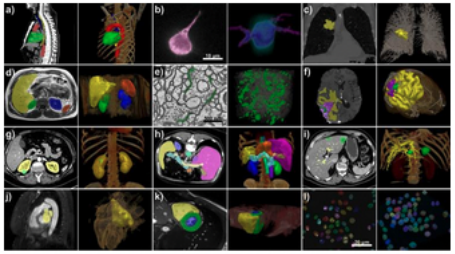

Audio

Tableaux

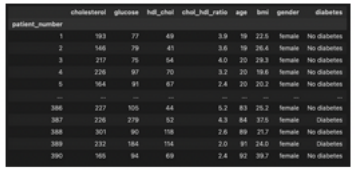

patient_number	cholesterol	glucose	hdl_chol	chol_hdl_ratio	age	bmi	gender	diabetes
1	193	77	49	3.9	19	22.5	female	No diabetes
2	146	79	41	3.6	19	26.4	female	No diabetes
3	217	75	54	4.0	20	29.3	female	No diabetes
4	226	97	70	3.2	20	19.6	female	No diabetes
5	164	91	67	2.4	20	20.2	female	No diabetes
...	...	...	...	...	...	...	...	...
386	227	105	44	5.2	83	25.2	female	No diabetes
387	226	279	52	4.3	84	37.5	female	Diabetes
388	301	90	118	2.6	89	21.7	female	No diabetes
389	232	184	114	2.0	91	24.0	female	Diabetes
390	165	94	69	2.4	92	39.7	female	No diabetes

Apprentissage automatique

Un ensemble d'algorithmes permettant à une machine d'apprendre un phénomène à partir de données

Texte

Image
vidéo

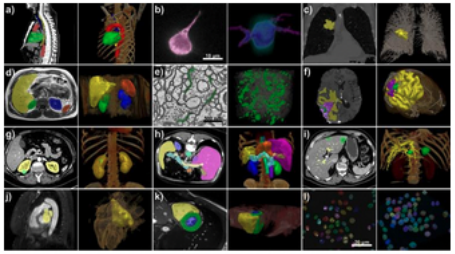

Audio

Tableaux

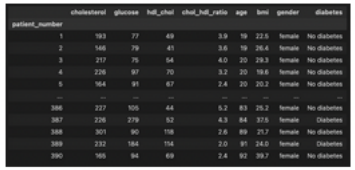

patient_number	cholesterol	glucose	hdl_chol	chol_hdl_ratio	age	bmi	gender	diabetes
1	193	77	49	3.9	19	22.5	female	No diabetes
2	146	79	41	3.6	19	26.4	female	No diabetes
3	217	75	54	4.0	20	29.3	female	No diabetes
4	226	97	70	3.2	20	19.6	female	No diabetes
5	164	91	67	2.4	20	20.2	female	No diabetes
...	...	...	...	...	...	...	...	...
386	227	105	44	5.2	83	25.2	female	No diabetes
387	226	279	52	4.3	84	37.5	female	Diabetes
388	301	90	118	2.6	89	21.7	female	No diabetes
389	232	184	114	2.0	91	24.0	female	Diabetes
390	165	94	69	2.4	92	39.7	female	No diabetes

Le processus d'apprentissage, souvent via des calculs très longs, donne un modèle

Algorithme versus Modèle

Algorithme

C'est un ensemble d'opérations permettant de résoudre une classe de problèmes

Exemple : $98 \times 2 = 100 \times 2 - 4$

$\longrightarrow$ Générique

Algorithme versus Modèle

Algorithme

C'est un ensemble d'opérations permettant de résoudre une classe de problèmes

Exemple : $98 \times 2 = 100 \times 2 - 4$

$\longrightarrow$ Générique

Modèle

Un modèle est le résultat d'un processus de calcul adapté aux données

`Modèle = Algorithme + Données`

$\longrightarrow$ Spécifique à des données

Exemple du diabète

Modèle 1

Diabète si :

- IMC > 30 pour les hommes
- IMC > 25 pour les femmes

IMC = Indice de masse corporelle = $\frac{\text{poids}}{\text{taille}^2}$

Exemple du diabète

Modèle 1

Diabète si :

- IMC > 30 pour les hommes $\rightarrow$ 70% de précision
- IMC > 25 pour les femmes $\rightarrow$ 35% de précision

ID	Gender	IMC	Diabetes
40	male	35.1	No diabetes
65	female	24.7	Diabetes
251	female	26.9	Diabetes
257	male	25.5	Diabetes
299	male	30.7	Diabetes
301	female	36.6	No diabetes

	Diabetes	No diabetes
Male		
IMC < 30	16	104
IMC ≥ 30	10	32
Female		
IMC < 25	3	48
IMC ≥ 25	31	146

IMC = Indice de masse corporelle = $\frac{\text{poids}}{\text{taille}^2}$

Exemple du diabète

Modèle 1

Diabète si :

- IMC > 30 pour les hommes
- IMC > 25 pour les femmes

Modèle 3

$$\text{Diabete} = \text{fonction}(\text{IMC}, \text{Age}, \text{Alimentation}, \text{etc.})$$

IMC = Indice de masse corporelle = $\frac{\text{poids}}{\text{taille}^2}$

Exemple du diabète

Modèle 1

Diabète si :

- IMC > 30 pour les hommes
- IMC > 25 pour les femmes

Modèle 2

$$\text{Diabete} = a * \text{IMC} + b * \text{Age} + c * \text{Alimentation} + \ldots$$

IMC = Indice de masse corporelle = $\frac{\text{poids}}{\text{taille}^2}$

Apprentissage supervisé

Données $\longrightarrow$ $\boxed{\text{Modèle supervisé}}$ $\longrightarrow$ Diabète

Objectif : **Prédire** un phénomène (le diabète) à partir d'**observations** (données récoltées sur les patients)

- Connaissance a priori de la variable d'intérêt

  $\rightarrow$ Faire le lien entre les observations et la variable d'intérêt

ID	Gender	IMC	Diabetes
40	male	35.1	No diabetes
65	female	24.7	Diabetes
251	female	26.9	Diabetes
257	male	25.5	Diabetes
299	male	30.7	Diabetes
301	female	36.6	No diabetes

Apprentissage supervisé

Données $\longrightarrow$ $\boxed{\text{Modèle supervisé}}$ $\longrightarrow$ Diabète

Objectif : **Prédire** un phénomène (le diabète) à partir d'**observations** (données récoltées sur les patients)

⚠ Trois étapes nécessaires :

1. Entrainement : phase d'apprentissage / construction du modèle
2. Inférence : prédiction de nouveaux cas
3. Test et évaluation : estimation de l'erreur commise

Apprentissage supervisé

Objectif : **Identifier** le chiffre manuscrit à partir d'un ensemble d'**images**

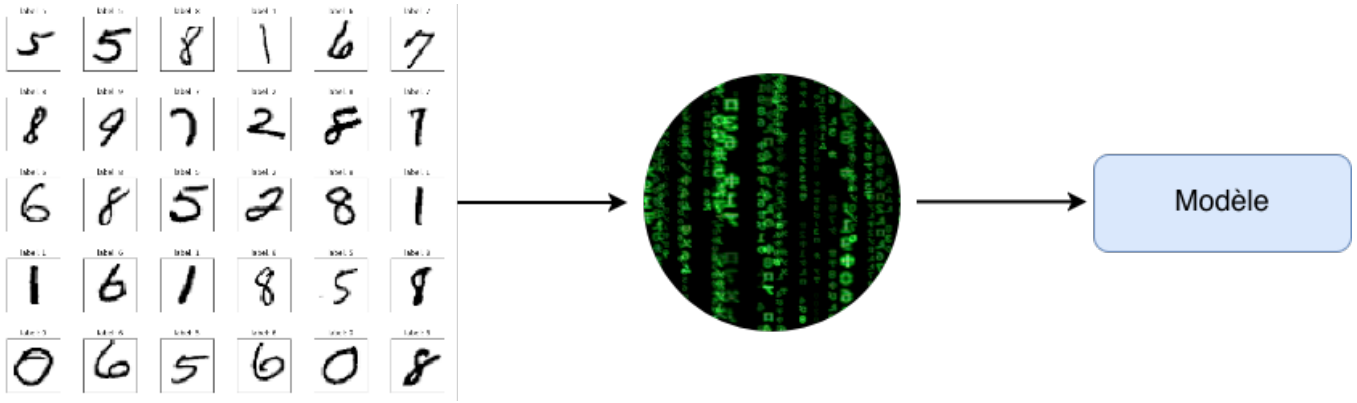

Apprentissage supervisé

Objectif : **Identifier** le chiffre manuscrit à partir d'un ensemble d'**images**

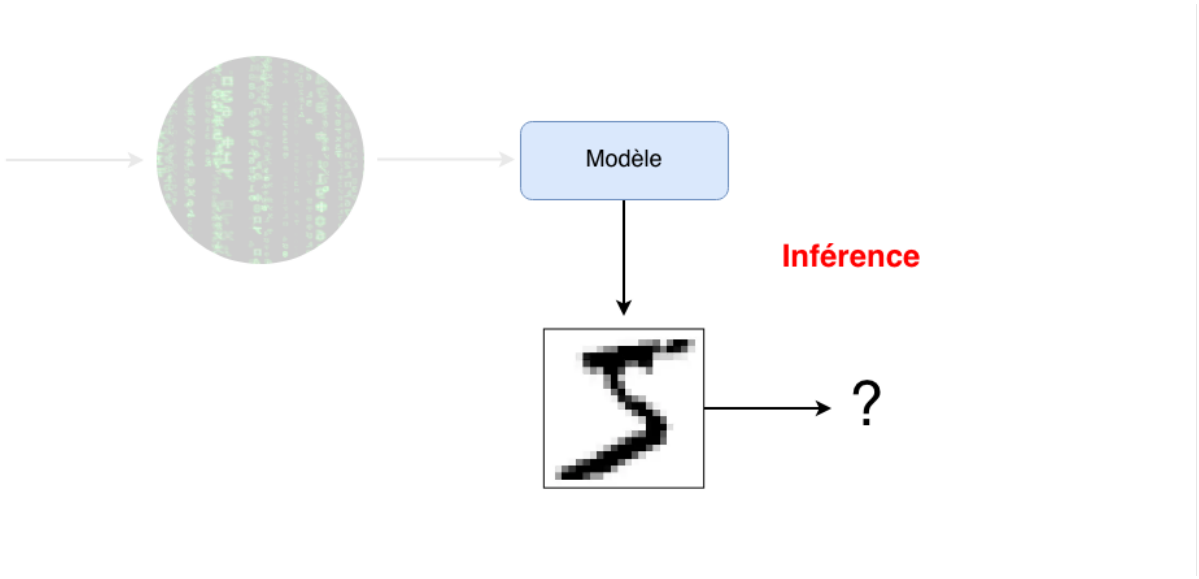

Apprentissage supervisé

Objectif : **Identifier** le chiffre manuscrit à partir d'un ensemble d'**images**

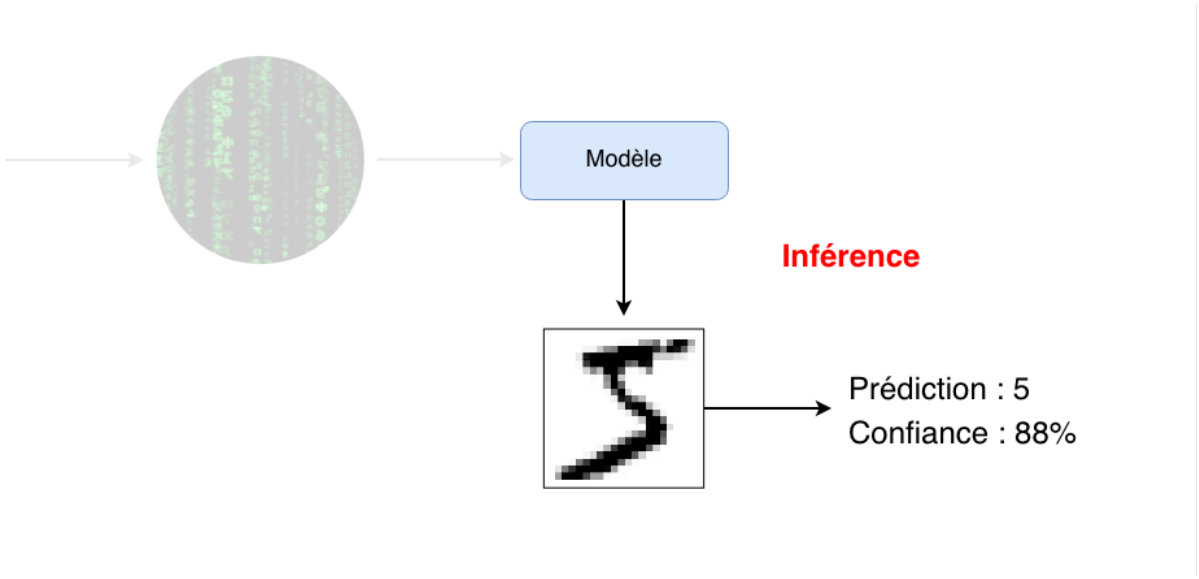

Apprentissage automatique en bref

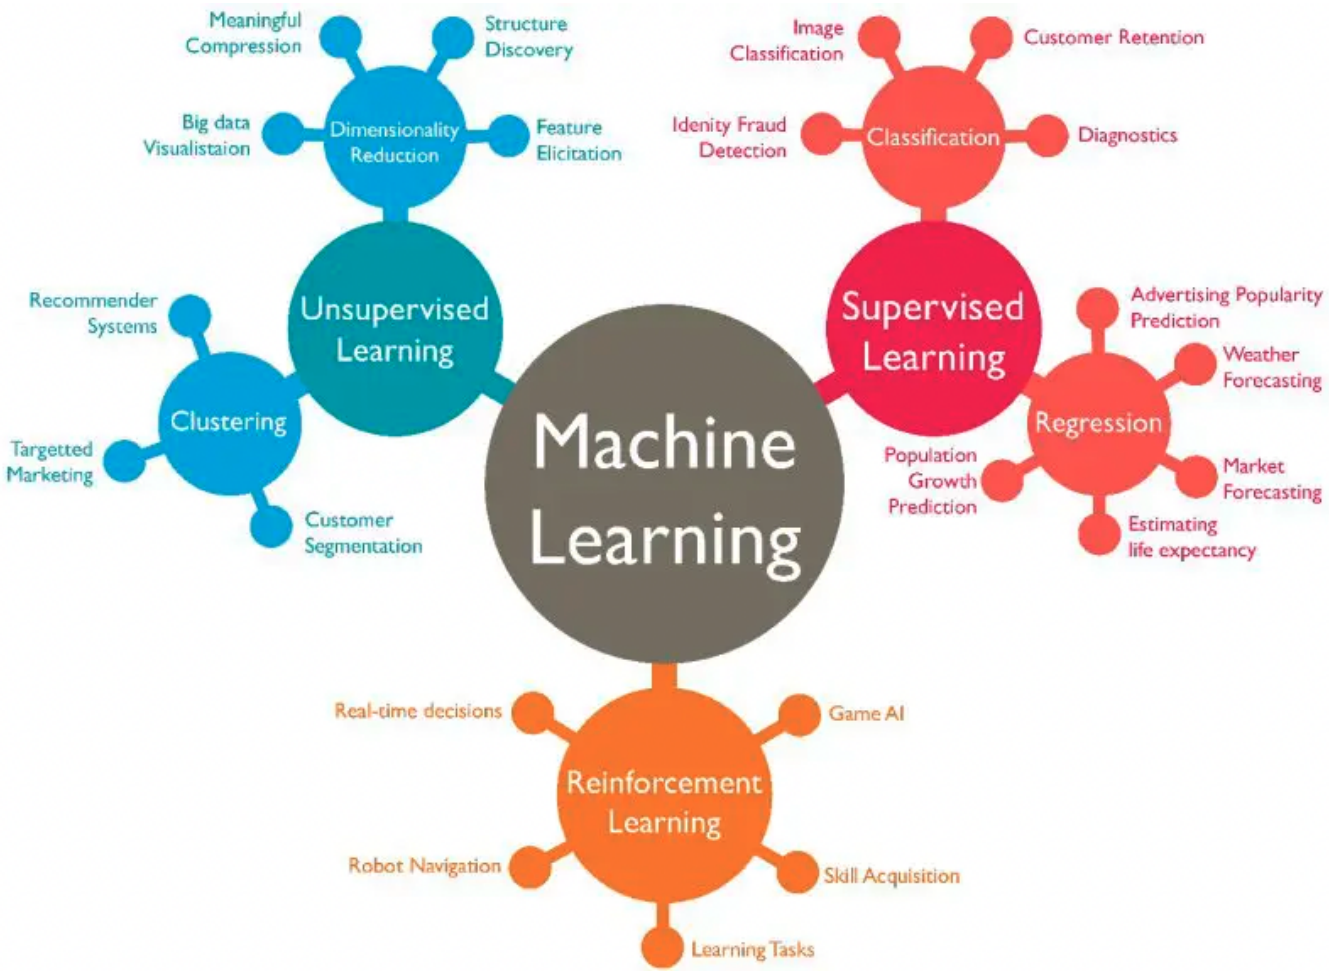

Merci pour votre attention

scai

SORBONNE CLUSTER FOR
ARTIFICIAL INTELLIGENCE