Introduction à l'exploration de données

IA, modèles, visualisation

Master Management de l'Innovation

Janvier 2026

Biais dans les modèles de langage

Rappels de la session précédente

NLP

- Fréquence des mots, extraction de mots clés
- Extraction des entités nommées
- Analyse de sentiment
- Plongement lexical

Rappels de la session précédente

NLP

- Fréquence des mots, extraction de mots clés
- Extraction des entités nommées
- Analyse de sentiment
- Plongement lexical

Cas d'usage

- Marketing ciblé
- Analyse des réseaux sociaux, détection de communautés
- Analyse de corpus de texte
- Indexation de bases de données documentaires

Rappels de la session précédente

Plongement lexical

Le plongement lexical, ou plongement sémantique, vise à représenter les mots sous forme de vecteurs.

Corpus

-0.32	-0.88	0.22	0.25	0.23	0.74	-0.38	-0.35	-0.84	-1.11	...
-0.50	-0.71	0.55	0.67	0.22	0.60	-0.26	0.74	-0.65	-0.22	...
0.37	0.39	0.71	-0.66	-0.00	0.93	0.28	-0.06	-0.24	0.25	...
0.59	0.45	0.59	0.07	0.11	1.28	0.17	0.24	0.39	0.33	...
-0.11	-0.87	0.48	0.73	0.12	0.32	0.07	0.50	-0.18	-0.12	...
-0.10	-0.45	0.73	0.33	0.74	0.27	-0.13	0.05	-0.58	-0.14	...
-0.60	-0.46	0.13	-0.02	0.46	-0.30	0.90	-0.66	0.67	-0.49	...
-0.34	0.46	-0.08	0.20	-0.18	-0.47	0.62	0.30	0.57	-0.35	...
-1.36	0.29	-0.39	0.41	0.34	0.04	0.85	0.39	0.55	-0.32	...
-0.15	0.16	-0.36	-0.72	0.62	0.74	0.69	0.40	-0.24	0.18	...
0.09	0.80	-0.02	-0.56	0.50	-0.19	0.05	0.06	-1.05	-0.64	...
-0.30	0.50	-0.13	-0.82	0.34	0.32	-0.05	0.04	-0.62	-0.22	...
0.01	0.34	-0.21	-0.94	0.73	0.58	0.29	0.16	-0.21	0.05	...
0.44	-0.06	0.31	0.61	0.36	-0.04	0.43	0.59	-0.00	-0.25	...

Vecteurs

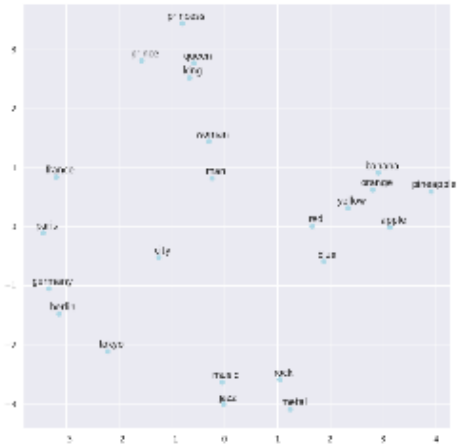

Visualisation

Rappels de la session précédente

Plongement lexical

Le plongement lexical, ou plongement sémantique, vise à représenter les mots sous forme de vecteurs.

Pourquoi ?

Pour utiliser les outils statistiques (visualisation et modélisation) tout simplement !

Rappels de la session précédente

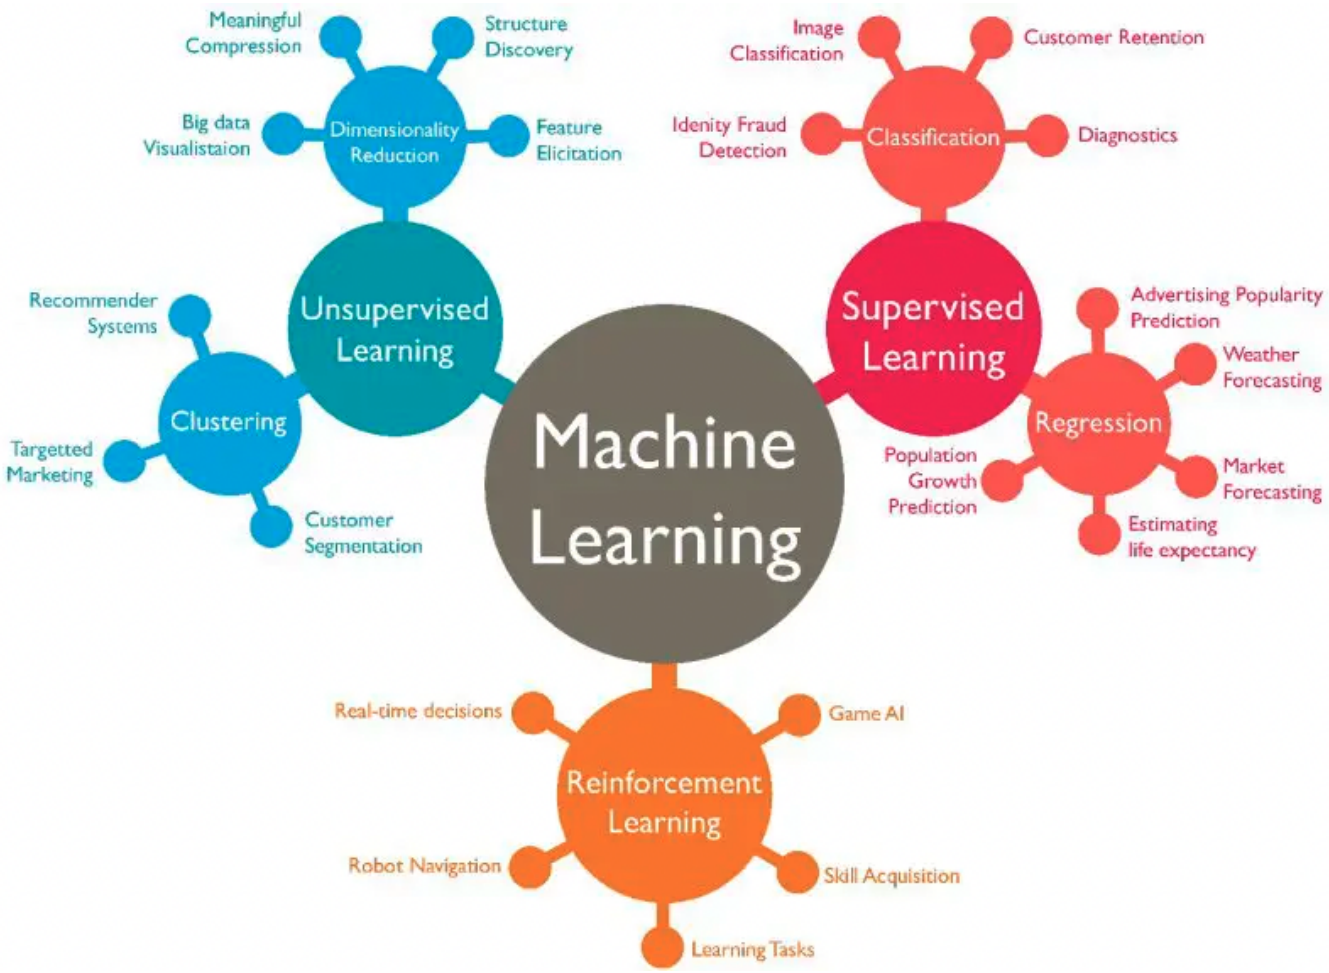

Modèle d'embeddings

Corpus

-0.32	-0.88	0.22	0.25	0.23	0.74	-0.38	-0.35	-0.84	-1.11	...
-0.50	-0.71	0.55	0.67	0.22	0.60	-0.26	0.74	-0.65	-0.22	...
0.37	0.39	0.71	-0.66	-0.00	0.93	0.28	-0.06	-0.24	0.25	...
0.59	0.45	0.59	0.07	0.11	1.28	0.17	0.24	0.39	0.33	...
-0.11	-0.87	0.48	0.73	0.12	0.32	0.07	0.50	-0.18	-0.12	...
-0.10	-0.45	0.73	0.33	0.74	0.27	-0.13	0.05	-0.58	-0.14	...
-0.60	-0.46	0.13	-0.02	0.46	-0.30	0.90	-0.66	0.67	-0.49	...
-0.34	0.46	-0.08	0.20	-0.18	-0.47	0.62	0.30	0.57	-0.35	...
-1.36	0.29	-0.39	0.41	0.34	0.04	0.85	0.39	0.55	-0.32	...
-0.15	0.16	-0.36	-0.72	0.62	0.74	0.69	0.40	-0.24	0.18	...
0.09	0.80	-0.02	-0.56	0.50	-0.19	0.05	0.06	-1.05	-0.64	...
-0.30	0.50	-0.13	-0.82	0.34	0.32	-0.05	0.04	-0.62	-0.22	...
0.01	0.34	-0.21	-0.94	0.73	0.58	0.29	0.16	-0.21	0.05	...
0.44	-0.06	0.31	0.61	0.36	-0.04	0.43	0.59	-0.00	-0.25	...

Vecteurs

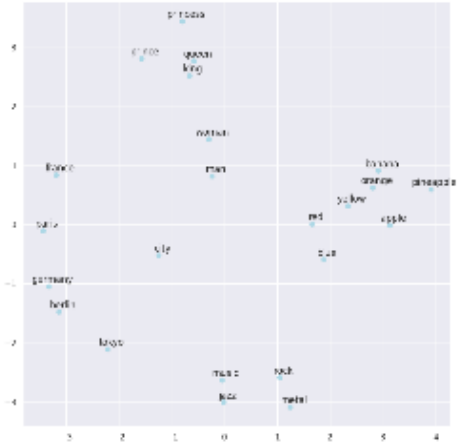

Visualisation

Modèle d'embeddings

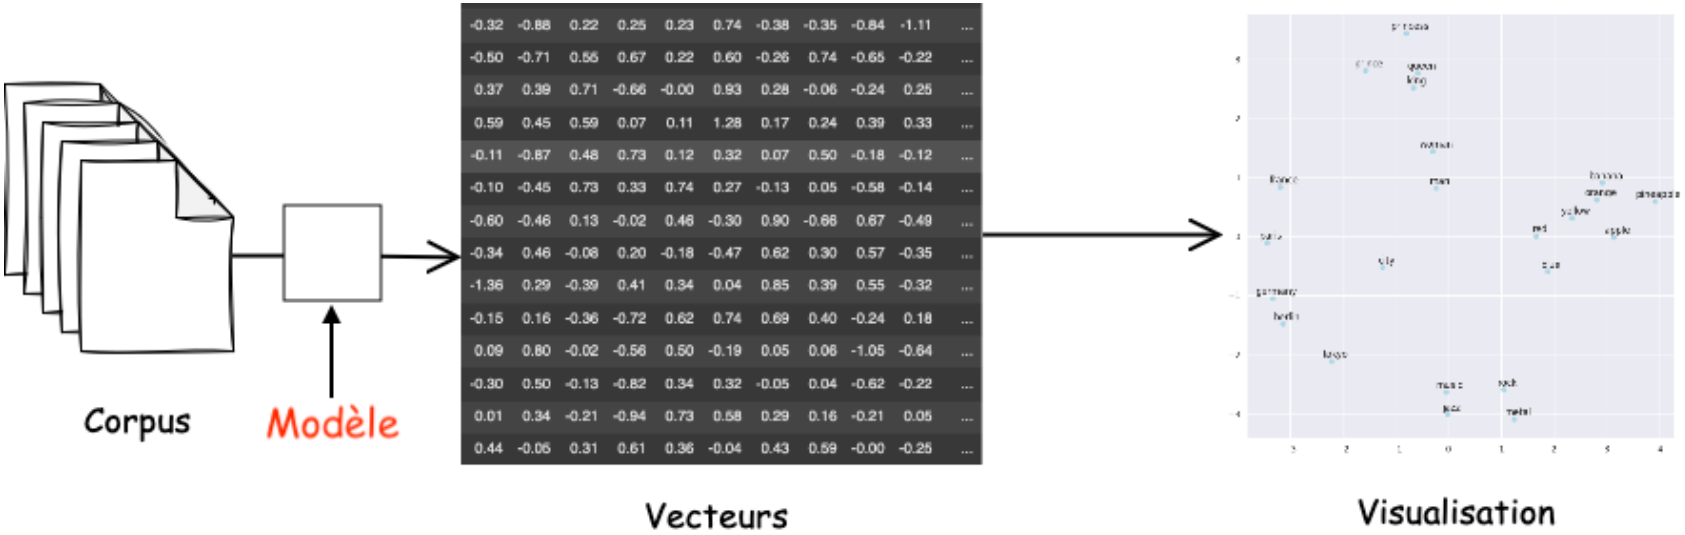

Modèle d'embeddings

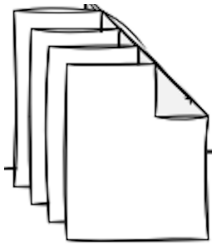

Modèle

-0.88	0.22	0.25	0.23	0.74	-0.38	-0.35	-0.84	-1.11
-0.71	0.55	0.67	0.22	0.60	-0.26	0.74	-0.65	-0.22
0.39	0.71	-0.66	-0.00	0.93	0.28	-0.08	-0.24	0.25
0.45	0.59	0.07	0.11	1.28	0.17	0.24	0.39	0.33
-0.87	0.48	0.73	0.12	0.32	0.07	0.50	-0.18	-0.12
-0.45	0.73	0.33	0.74	0.27	-0.13	0.05	-0.58	-0.14
-0.46	0.13	-0.02	0.46	-0.30	0.90	-0.66	0.67	-0.49
0.46	-0.08	0.20	-0.18	-0.47	0.62	0.30	0.57	-0.35
0.29	-0.39	0.41	0.34	0.04	0.85	0.39	0.55	-0.32
0.16	-0.36	-0.72	0.62	0.74	0.69	0.40	-0.24	0.18
0.80	-0.02	-0.56	0.50	-0.19	0.05	0.08	-1.05	-0.64
0.50	-0.13	-0.82	0.34	0.32	-0.05	0.04	-0.62	-0.22
0.34	-0.21	-0.94	0.73	0.58	0.29	0.16	-0.21	0.05

Modèle d'embeddings

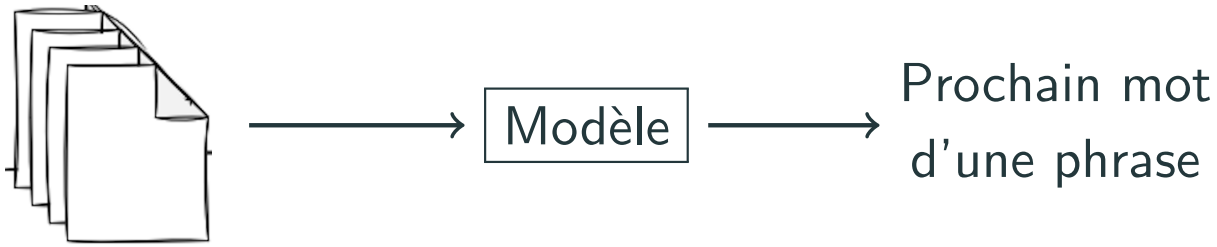

Biais dans les modèles de langage

Les modèles de langage sont fortement influencés par les données d'apprentissage, ainsi que leur biais

---

Modèles d'embeddings

Word2Vec
GloVe

Modèles Transformers

BERT
GPT-2 and co

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Biais algorithmique

Algorithmic bias describes systematic and repeatable errors in a computer system that create "unfair" outcomes, such as "privileging" one category over another [...]

D'après en.wikipedia.org/wiki/Algorithmic_bias

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Biais algorithmique

Algorithmic bias describes systematic and repeatable errors in a computer system that create "unfair" outcomes, such as "privileging" one category over another [...]

D'après en.wikipedia.org/wiki/Algorithmic_bias

Impacts des biais algorithmiques

- Renforce les stéréotypes sociétaux[a]
- Conduit à des résultats injustes ou nuisibles dans des applications réelles (ex: systèmes de recrutement, algorithmes judiciaires)
- etc.

[a] Gallegos et al (2024) *Bias and Fairness in Large Language Models: A Survey*

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Biais en apprentissage automatique

Machine learning bias describes systematic and repeatable errors in a data-based computer system that create "unfair" outcomes, such as "privileging" one category over another [...]

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Types de biais en apprentissage automatique

- **Biais de données**
  Reflète les stéréotypes dans le jeu de données d'entraînement

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Types de biais en apprentissage automatique

- **Biais de données**
  Reflète les stéréotypes dans le jeu de données d'entraînement
- **Biais algorithmique**
  Provient des décisions d'implémentation dans le modèle

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Types de biais en apprentissage automatique

- **Biais de données**
  Reflète les stéréotypes dans le jeu de données d'entraînement
- **Biais algorithmique**
  Provient des décisions d'implémentation dans le modèle
- **Biais d'évaluation**
  Résulte des benchmarks utilisés pour évaluer le modèle

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Types de biais en apprentissage automatique

- **Biais de données**
  Reflète les stéréotypes dans le jeu de données d'entraînement
- **Biais algorithmique**
  Provient des décisions d'implémentation dans le modèle
- **Biais d'évaluation**
  Résulte des benchmarks utilisés pour évaluer le modèle

Exemples clés

- Un LLM entraîné principalement sur des textes anglais peut mal performer sur des tweets non-anglais
- Analogies de mots genrées : "L'homme est au médecin ce que la femme est à l'infirmière"

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Types de biais en apprentissage automatique

- **Biais de données**
  Reflète les stéréotypes dans le jeu de données d'entraînement
- **Biais algorithmique**
  Provient des décisions d'implémentation dans le modèle
- **Biais d'évaluation**
  Résulte des benchmarks utilisés pour évaluer le modèle

Et le "biais sociétal" ?

Beaucoup de stéréotypes dans notre société $\rightarrow$ effet sur les jeux de données

ex: réseaux sociaux

Qu'est-ce que le biais dans les algorithmes et l'apprentissage automatique ?

Types de biais en apprentissage automatique

- **Biais de données**
  Reflète les stéréotypes dans le jeu de données d'entraînement
- **Biais algorithmique**
  Provient des décisions d'implémentation dans le modèle
- **Biais d'évaluation**
  Résulte des benchmarks utilisés pour évaluer le modèle

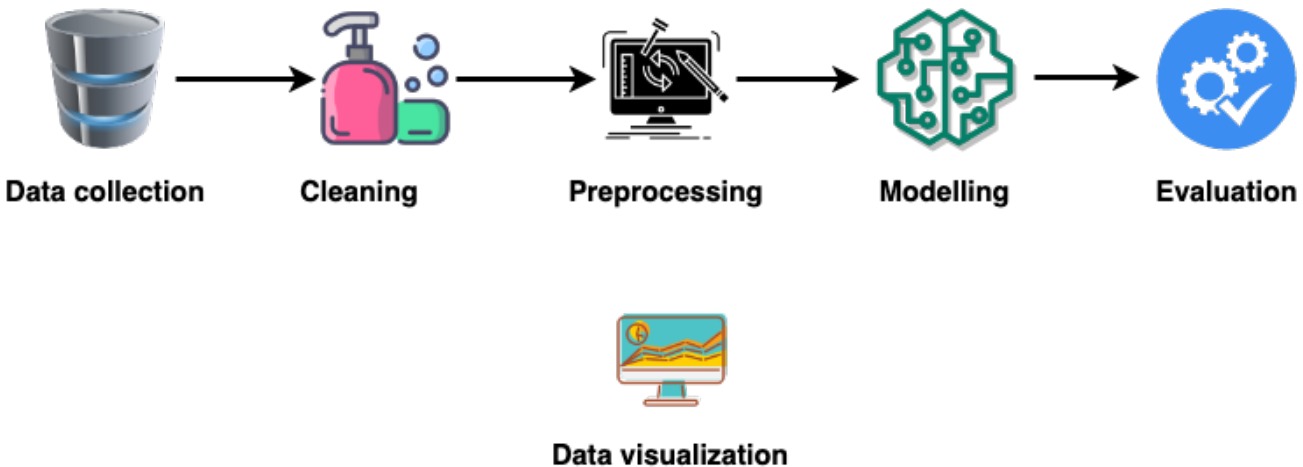

Des modèles anciens aux LLM modernes

Le biais : un problème bien documenté

Les modèles anciens comme **Word2Vec** et **BERT** héritaient des biais de leurs données d'entraînement

- Stéréotypes de genre : "médecin" associé aux hommes, "infirmière" aux femmes

Des modèles anciens aux LLM modernes

Le biais : un problème bien documenté

Les modèles anciens comme **Word2Vec** et **BERT** héritaient des biais de leurs données d'entraînement

- Stéréotypes de genre : "médecin" associé aux hommes, "infirmière" aux femmes
- Biais professionnels : certains métiers liés plus fortement à des genres spécifiques

Des modèles anciens aux LLM modernes

Le biais : un problème bien documenté

Les modèles anciens comme **Word2Vec** et **BERT** héritaient des biais de leurs données d'entraînement

- Stéréotypes de genre : "médecin" associé aux hommes, "infirmière" aux femmes
- Biais professionnels : certains métiers liés plus fortement à des genres spécifiques
- Stéréotypes raciaux : associations problématiques apprises du texte

Des modèles anciens aux LLM modernes

Le biais : un problème bien documenté

Les modèles anciens comme **Word2Vec** et **BERT** héritaient des biais de leurs données d'entraînement

- Stéréotypes de genre : "médecin" associé aux hommes, "infirmière" aux femmes
- Biais professionnels : certains métiers liés plus fortement à des genres spécifiques
- Stéréotypes raciaux : associations problématiques apprises du texte

Qu'en est-il des LLM modernes ?

Des modèles comme GPT-4, CLAUDE, LLAMA ont fait des progrès significatifs

Mais le biais n'est pas complètement éliminé

Progrès dans les LLM modernes

Techniques avancées pour réduire les biais

- **Données d'entraînement diversifiées**
  Collectées depuis plusieurs sources, langues et cultures

Progrès dans les LLM modernes

Techniques avancées pour réduire les biais

- **Données d'entraînement diversifiées**
  Collectées depuis plusieurs sources, langues et cultures
- **Débiaisage adversarial**
  Entraînement d'un modèle additionnel pour identifier et réduire les biais pendant l'entraînement

Progrès dans les LLM modernes

Techniques avancées pour réduire les biais

- **Données d'entraînement diversifiées**
  Collectées depuis plusieurs sources, langues et cultures
- **Débiaisage adversarial**
  Entraînement d'un modèle additionnel pour identifier et réduire les biais pendant l'entraînement
- **Ajustement fin pour l'équité**
  Utilisation de jeux de données spécifiquement conçus pour contrer les stéréotypes

Progrès dans les LLM modernes

Techniques avancées pour réduire les biais

- **Données d'entraînement diversifiées**
  Collectées depuis plusieurs sources, langues et cultures
- **Débiaisage adversarial**
  Entraînement d'un modèle additionnel pour identifier et réduire les biais pendant l'entraînement
- **Ajustement fin pour l'équité**
  Utilisation de jeux de données spécifiquement conçus pour contrer les stéréotypes
- **Ajustements post-hoc**
  Signalement ou reformulation des sorties potentiellement biaisées avant de les montrer

Progrès dans les LLM modernes

Évaluation et garde-fous améliorés

- **Évaluation complète**
  Tests sur plusieurs dimensions : genre, race, âge, profession, culture

Progrès dans les LLM modernes

Évaluation et garde-fous améliorés

- **Évaluation complète**
  Tests sur plusieurs dimensions : genre, race, âge, profession, culture
- **Directives éthiques**
  Équipes diversifiées, tests approfondis, auditeurs externes, transparence sur les limites

Progrès dans les LLM modernes

Évaluation et garde-fous améliorés

- **Évaluation complète**
  Tests sur plusieurs dimensions : genre, race, âge, profession, culture
- **Directives éthiques**
  Équipes diversifiées, tests approfondis, auditeurs externes, transparence sur les limites
- **Surveillance continue**
  Audits réguliers pour détecter de nouveaux biais après les mises à jour du modèle

Comment atténuer les biais ?

Collecte et prétraitement des données

- Collecter des jeux de données diversifiés et représentatifs
- Supprimer les caractéristiques biaisées

Comment atténuer les biais ?

Construction du modèle

- Choisir des algorithmes non biaisés
- Éviter le surapprentissage : sélection du modèle et des caractéristiques

Comment atténuer les biais ?

Évaluation

- Utiliser des métriques d'équité
- Éviter le surapprentissage : sélection du modèle et des caractéristiques

Gallegos et al (2024)
Bias and Fairness in Large Language Models: A Survey

Caton, Haas (2024)
Fairness in Machine Learning: A Survey

Comment atténuer les biais ?

En général

- Être transparent dans tous les processus de modélisation
- Surveiller toutes les étapes : prétraitement, modélisation, etc.

Défis qui persistent

Pourquoi l'élimination complète est difficile

- **Limitations des données**
  Les données d'entraînement reflètent les biais sociétaux présents dans les corpus textuels

Défis qui persistent

Pourquoi l'élimination complète est difficile

- **Limitations des données**
  Les données d'entraînement reflètent les biais sociétaux présents dans les corpus textuels
- **Biais subtils et contextuels**
  Pas toujours des stéréotypes manifestes, mais des influences nuancées sur le comportement

Défis qui persistent

Pourquoi l'élimination complète est difficile

- **Limitations des données**
  Les données d'entraînement reflètent les biais sociétaux présents dans les corpus textuels
- **Biais subtils et contextuels**
  Pas toujours des stéréotypes manifestes, mais des influences nuancées sur le comportement
- **Nature dynamique**
  Les normes sociétales évoluent $\rightarrow$ les modèles nécessitent des mises à jour continues

Défis qui persistent

Pourquoi l'élimination complète est difficile

- **Limitations des données**
  Les données d'entraînement reflètent les biais sociétaux présents dans les corpus textuels
- **Biais subtils et contextuels**
  Pas toujours des stéréotypes manifestes, mais des influences nuancées sur le comportement
- **Nature dynamique**
  Les normes sociétales évoluent $\rightarrow$ les modèles nécessitent des mises à jour continues
- **Compromis**
  Réduire les biais dans un domaine peut en affecter un autre

Exemples de biais persistants

Même les LLM modernes peuvent présenter

- **Biais de genre**
  Les rôles de leadership toujours plus associés aux hommes

Exemples de biais persistants

Même les LLM modernes peuvent présenter

- **Biais de genre**
  Les rôles de leadership toujours plus associés aux hommes
- **Biais culturel**
  Les modèles entraînés principalement sur du texte occidental peuvent mal se généraliser à d'autres cultures

Exemples de biais persistants

Même les LLM modernes peuvent présenter

- **Biais de genre**
  Les rôles de leadership toujours plus associés aux hommes
- **Biais culturel**
  Les modèles entraînés principalement sur du texte occidental peuvent mal se généraliser à d'autres cultures
- **Stéréotypes professionnels**
  Certaines professions liées à des groupes démographiques spécifiques

Exemples de biais persistants

Même les LLM modernes peuvent présenter

- **Biais de genre**
  Les rôles de leadership toujours plus associés aux hommes
- **Biais culturel**
  Les modèles entraînés principalement sur du texte occidental peuvent mal se généraliser à d'autres cultures
- **Stéréotypes professionnels**
  Certaines professions liées à des groupes démographiques spécifiques

Important
Les LLM modernes sont meilleurs que les modèles anciens, mais pas exempts de biais

Tester les LLM pour les biais : vue d'ensemble

Une approche systématique

Identifier les biais nécessite de combiner :

- Analyse quantitative : métriques et statistiques

Tester les LLM pour les biais : vue d'ensemble

Une approche systématique

Identifier les biais nécessite de combiner :

- Analyse quantitative : métriques et statistiques
- Évaluation qualitative : examen humain

Tester les LLM pour les biais : vue d'ensemble

Une approche systématique

Identifier les biais nécessite de combiner :

- Analyse quantitative : métriques et statistiques
- Évaluation qualitative : examen humain
- Évaluation en conditions réelles : tests de déploiement

Tester les LLM pour les biais : vue d'ensemble

Une approche systématique

Identifier les biais nécessite de combiner :

- Analyse quantitative : métriques et statistiques
- Évaluation qualitative : examen humain
- Évaluation en conditions réelles : tests de déploiement

Première étape : définir quoi tester

Dimensions courantes :

- Genre, race/ethnicité, âge
- Profession, culture/région
- Statut socioéconomique

Méthodes de test : cadres d'évaluation

Utiliser des benchmarks existants

- **StereoSet**
  Jeu de données mesurant les associations entre attributs et stéréotypes

Méthodes de test : cadres d'évaluation

Utiliser des benchmarks existants

- **StereoSet**
  Jeu de données mesurant les associations entre attributs et stéréotypes
- **CrowS-Pairs**
  Évalue les associations entre race et attributs

Méthodes de test : cadres d'évaluation

Utiliser des benchmarks existants

- **StereoSet**
  Jeu de données mesurant les associations entre attributs et stéréotypes
- **CrowS-Pairs**
  Évalue les associations entre race et attributs
- **SEAT (Sentence Encoder Association Test)**
  Teste les biais dans les embeddings de phrases

Méthodes de test : cadres d'évaluation

Utiliser des benchmarks existants

- **StereoSet**
  Jeu de données mesurant les associations entre attributs et stéréotypes
- **CrowS-Pairs**
  Évalue les associations entre race et attributs
- **SEAT (Sentence Encoder Association Test)**
  Teste les biais dans les embeddings de phrases

Métriques d'équité

- **Impact disparate** : mesurer les disparités entre groupes
- **Égalité des chances** : taux d'erreur similaires entre groupes

Méthodes de test : conception de prompts

Concevoir des prompts pour révéler les biais

- **Prompts sur les professions**
  "Un(e) [genre] a plus de chances d'être [profession]"
  Comparer : homme/PDG vs. femme/PDG

Méthodes de test : conception de prompts

Concevoir des prompts pour révéler les biais

- **Prompts sur les professions**
  "Un(e) [genre] a plus de chances d'être [profession]"
  Comparer : homme/PDG vs. femme/PDG
- **Association d'attributs**
  "Un(e) [groupe démographique] est souvent..."

Méthodes de test : conception de prompts

Concevoir des prompts pour révéler les biais

- **Prompts sur les professions**
  "Un(e) [genre] a plus de chances d'être [profession]"
  Comparer : homme/PDG vs. femme/PDG
- **Association d'attributs**
  "Un(e) [groupe démographique] est souvent..."
- **Résolution de coréférence**
  "Sarah et David sont allés à la fête. Elle a apporté un gâteau."
  Le modèle favorise-t-il les pronoms masculins ou féminins ?

Méthodes de test : techniques avancées

Aller plus loin

- **Tests contrefactuels**
  Comparer les sorties pour des entrées similaires mais démographiquement différentes
  Exemple : “Un étudiant de Harvard” vs. “Un étudiant d’une université locale”

Méthodes de test : techniques avancées

Aller plus loin

- **Tests contrefactuels**
  Comparer les sorties pour des entrées similaires mais démographiquement différentes
  Exemple : "Un étudiant de Harvard" vs. "Un étudiant d'une université locale"
- **Tests de stress**
  Utiliser des prompts adversariaux conçus pour déclencher des réponses biaisées

Méthodes de test : techniques avancées

Aller plus loin

- **Tests contrefactuels**
  Comparer les sorties pour des entrées similaires mais démographiquement différentes
  Exemple : "Un étudiant de Harvard" vs. "Un étudiant d'une université locale"
- **Tests de stress**
  Utiliser des prompts adversariaux conçus pour déclencher des réponses biaisées
- **Analyse d'embeddings**
  Analyser les embeddings de mots/phrases pour détecter des associations biaisées (ex : utiliser WEAT)

Outils et ressources

Jeux de données

- StereoSet: `https://github.com/princeton-nlp/StereoSet`
- CrowS-Pairs: `https://github.com/nyu-mll/crows-pairs`
- SEAT: `https://github.com/nyu-mll/SEAT`

Bibliothèques

- `Aequitas` : métriques d'équité
- `fairlearn` : atténuation des biais
- Outils d'évaluation des biais de HuggingFace

Exemple de flux de travail

Tester les biais de genre dans les descriptions de poste

1. **Définir le périmètre** : biais de genre dans les professions

Exemple de flux de travail

Tester les biais de genre dans les descriptions de poste

1. **Définir le périmètre** : biais de genre dans les professions
2. **Collecter les données** : utiliser les prompts StereoSet
   "Un(e) [genre] est un meilleur leader"

Exemple de flux de travail

Tester les biais de genre dans les descriptions de poste

1. **Définir le périmètre** : biais de genre dans les professions
2. **Collecter les données** : utiliser les prompts StereoSet
   "Un(e) [genre] est un meilleur leader"
3. **Exécuter les tests** : saisir les prompts, collecter les sorties

Exemple de flux de travail

Tester les biais de genre dans les descriptions de poste

1. **Définir le périmètre** : biais de genre dans les professions
2. **Collecter les données** : utiliser les prompts StereoSet
   "Un(e) [genre] est un meilleur leader"
3. **Exécuter les tests** : saisir les prompts, collecter les sorties
4. **Analyser** : calculer les disparités
   % de traits positifs pour les hommes vs. les femmes

Exemple de flux de travail

Tester les biais de genre dans les descriptions de poste

1. **Définir le périmètre** : biais de genre dans les professions
2. **Collecter les données** : utiliser les prompts StereoSet
   "Un(e) [genre] est un meilleur leader"
3. **Exécuter les tests** : saisir les prompts, collecter les sorties
4. **Analyser** : calculer les disparités
   % de traits positifs pour les hommes vs. les femmes
5. **Examiner** : vérification manuelle des biais subtils

Exemple de flux de travail

Tester les biais de genre dans les descriptions de poste

1. **Définir le périmètre** : biais de genre dans les professions
2. **Collecter les données** : utiliser les prompts StereoSet
   "Un(e) [genre] est un meilleur leader"
3. **Exécuter les tests** : saisir les prompts, collecter les sorties
4. **Analyser** : calculer les disparités
   % de traits positifs pour les hommes vs. les femmes
5. **Examiner** : vérification manuelle des biais subtils
6. **Atténuer** : ajuster finement sur des données débiaisées si nécessaire

Points clés à retenir

À retenir

- **Le biais est multidimensionnel**
  Tester sur le genre, la race, l'âge, la culture, etc.

Points clés à retenir

À retenir

- **Le biais est multidimensionnel**
  Tester sur le genre, la race, l'âge, la culture, etc.
- **Combiner les méthodes**
  Utiliser à la fois les métriques automatisées et l'évaluation humaine

Points clés à retenir

À retenir

- **Le biais est multidimensionnel**
  Tester sur le genre, la race, l'âge, la culture, etc.
- **Combiner les méthodes**
  Utiliser à la fois les métriques automatisées et l'évaluation humaine
- **Itérer en continu**
  Les tests de biais doivent être continus, pas ponctuels

Points clés à retenir

À retenir

- **Le biais est multidimensionnel**
  Tester sur le genre, la race, l'âge, la culture, etc.
- **Combiner les méthodes**
  Utiliser à la fois les métriques automatisées et l'évaluation humaine
- **Itérer en continu**
  Les tests de biais doivent être continus, pas ponctuels
- **Être transparent**
  Documenter la méthodologie pour la reproductibilité et la responsabilité

Points clés à retenir

À retenir

- **Le biais est multidimensionnel**
  Tester sur le genre, la race, l'âge, la culture, etc.
- **Combiner les méthodes**
  Utiliser à la fois les métriques automatisées et l'évaluation humaine
- **Itérer en continu**
  Les tests de biais doivent être continus, pas ponctuels
- **Être transparent**
  Documenter la méthodologie pour la reproductibilité et la responsabilité

Objectif : Assurer l'équité et l'inclusivité dans les systèmes d'IA

Langage Python

Comment faire du data mining en pratique ?

- **Python** : langage versatile avec bibliothèques puissantes (pandas, scikit-learn, numpy)

Comment faire du data mining en pratique ?

- **Python** : langage versatile avec bibliothèques puissantes (pandas, scikit-learn, numpy)
- **R** : langage statistique avec écosystème riche pour l'analyse

Comment faire du data mining en pratique ?

- **Python** : langage versatile avec bibliothèques puissantes (pandas, scikit-learn, numpy)
- **R** : langage statistique avec écosystème riche pour l'analyse
- **SQL** : interrogation et manipulation de bases de données

Comment faire du data mining en pratique ?

- **Python** : langage versatile avec bibliothèques puissantes (pandas, scikit-learn, numpy)
- **R** : langage statistique avec écosystème riche pour l'analyse
- **SQL** : interrogation et manipulation de bases de données
- **Spark** : traitement distribué de grands volumes de données

Comment faire du data mining en pratique ?

- **Python** : langage versatile avec bibliothèques puissantes (pandas, scikit-learn, numpy)
- **R** : langage statistique avec écosystème riche pour l'analyse
- **SQL** : interrogation et manipulation de bases de données
- **Spark** : traitement distribué de grands volumes de données
- **Tableau, Power BI** : visualisation et exploration interactive

Quelques rappels : variables et types

La syntaxe de Python repose sur une série d'instructions et des mots clés bien précis

```
a = 1
print(a) # affiche 1
```

Quelques rappels : variables et types

La syntaxe de Python repose sur une série d'instructions et des mots clés bien précis

```
a = 1
print(a) # affiche 1
```

- a est une **variable** et 1 est sa **valeur**

Quelques rappels : variables et types

La syntaxe de Python repose sur une série d'instructions et des mots clés bien précis

```
a = 1
print(a) # affiche 1
```

- a est une **variable** et 1 est sa **valeur**
- la variable a a un type

```
print(type(a)) # affiche 'int'
```

Quelques rappels : variables et types

La syntaxe de Python repose sur une série d'instructions et des mots clés bien précis

```
a = 3.14
print(a) # affiche 3.14
```

- a est une **variable** et 3.14 est sa **valeur**
- la variable a a un type

```
print(type(a)) # affiche 'float'
```

Quelques rappels : variables et types

La syntaxe de Python repose sur une série d'instructions et des mots clés bien précis

```
a = "python"
print(a) # affiche "python"
```

- a est une **variable** et "python" est sa **valeur**
- la variable a a un type

```
print(type(a)) # affiche 'str'
```

Quelques rappels : variables et types

La syntaxe de Python repose sur une série d'instructions et des mots clés bien précis

```
a = [1, 2, 3]
print(a) # affiche [1, 2, 3]
```

- a est une **variable** et [1, 2, 3] est sa **valeur**
- la variable a a un type

```
print(type(a)) # affiche 'list'
```

Quelques rappels : variables et types

Opérations mathématiques

Les opérations mathématiques sont définies en python pour les types numériques (entiers, réels).
Certaines le sont aussi pour les **chaînes de caractères**

```
5 + 4 # donne 9
"He" + "llo" # donne "Hello"
"Hello" * 2 # donne "HelloHello"
```

Quelques rappels : syntaxte

Syntaxe en blocs indentés

- Indentation : décalage de lignes de code
- Délimiter des blocs logiques

```
dice = [1, 2, 3, 4, 5, 6]
value = random.choice(dice)
if value == 6:
    print(value, "You won!")
else:
    print(value, "Try again!")
```

Fonctions

Définition

Une fonction est une portion du code qui effectue une tâche précise. Elle permet

- de structurer le code
- d'éviter de dupliquer des parties du code, de simplifier la lecture

```
def fct(a, b, c):
    d = (a + b) * c
    return d


fct(1, 2, 3)
fct("py", "thon", 3)
```

Fonctions

Définition

Une fonction est une portion du code qui effectue une tâche précise. Elle permet

- de structurer le code
- d'éviter de dupliquer des parties du code, de simplifier la lecture

```
def fct(a=1, b=1, c=1):
    d = (a + b) * c
    return d

fct()
fct(1, 2, 3)
fct("py", "thon", 3)
```

Fonctions

Définition

Une fonction est une portion du code qui effectue une tâche précise. Elle permet

- de structurer le code
- d'éviter de dupliquer des parties du code, de simplifier la lecture

```
def play():
    dice = [1, 2, 3, 4, 5, 6]
    value = random.choice(dice)
    if value == 6:
        print(value, "You won!")
    else:
        print(value, "Try again!")

play()
play()
play()
```

Modules et imports

Modules

Python est structuré en un ensemble de modules correspondant à des tâches spécifiques

- `random` : simulation aléatoire
- `matplotlib` : visualisation de données
- `nltk, spacy` : analyse textuelle

Modules et imports

Modules

Python est structuré en un ensemble de modules correspondant à des tâches spécifiques

- `random` : simulation aléatoire
- `matplotlib` : visualisation de données
- `nltk, spacy` : analyse textuelle

Dans chaque module

- d'autres modules
- des fonctions

```
import random
random.choice([1, 2, 3, 4, 5, 6])
```

Modules NLTK et SpaCy

NLTK et SpaCy sont deux boites à outils pour l'analyse textuelle.

Large éventail de fonctionnalités : tokenization, lemmatization, mots clés, etc.

Aspect	**NLTK**	**SpaCy**
Objectif principal	Exploration	Production
Facilité	Simple	Simple
Performances	Plus lent	Optimisé pour la vitesse
Fonctionnalités modernes	Moins avancé	Modèles pré-entraînés contextuels
Modèles pré-entraînés	Implémentation manuelle	Intégrés et faciles d'accès

Quid des LLM ?

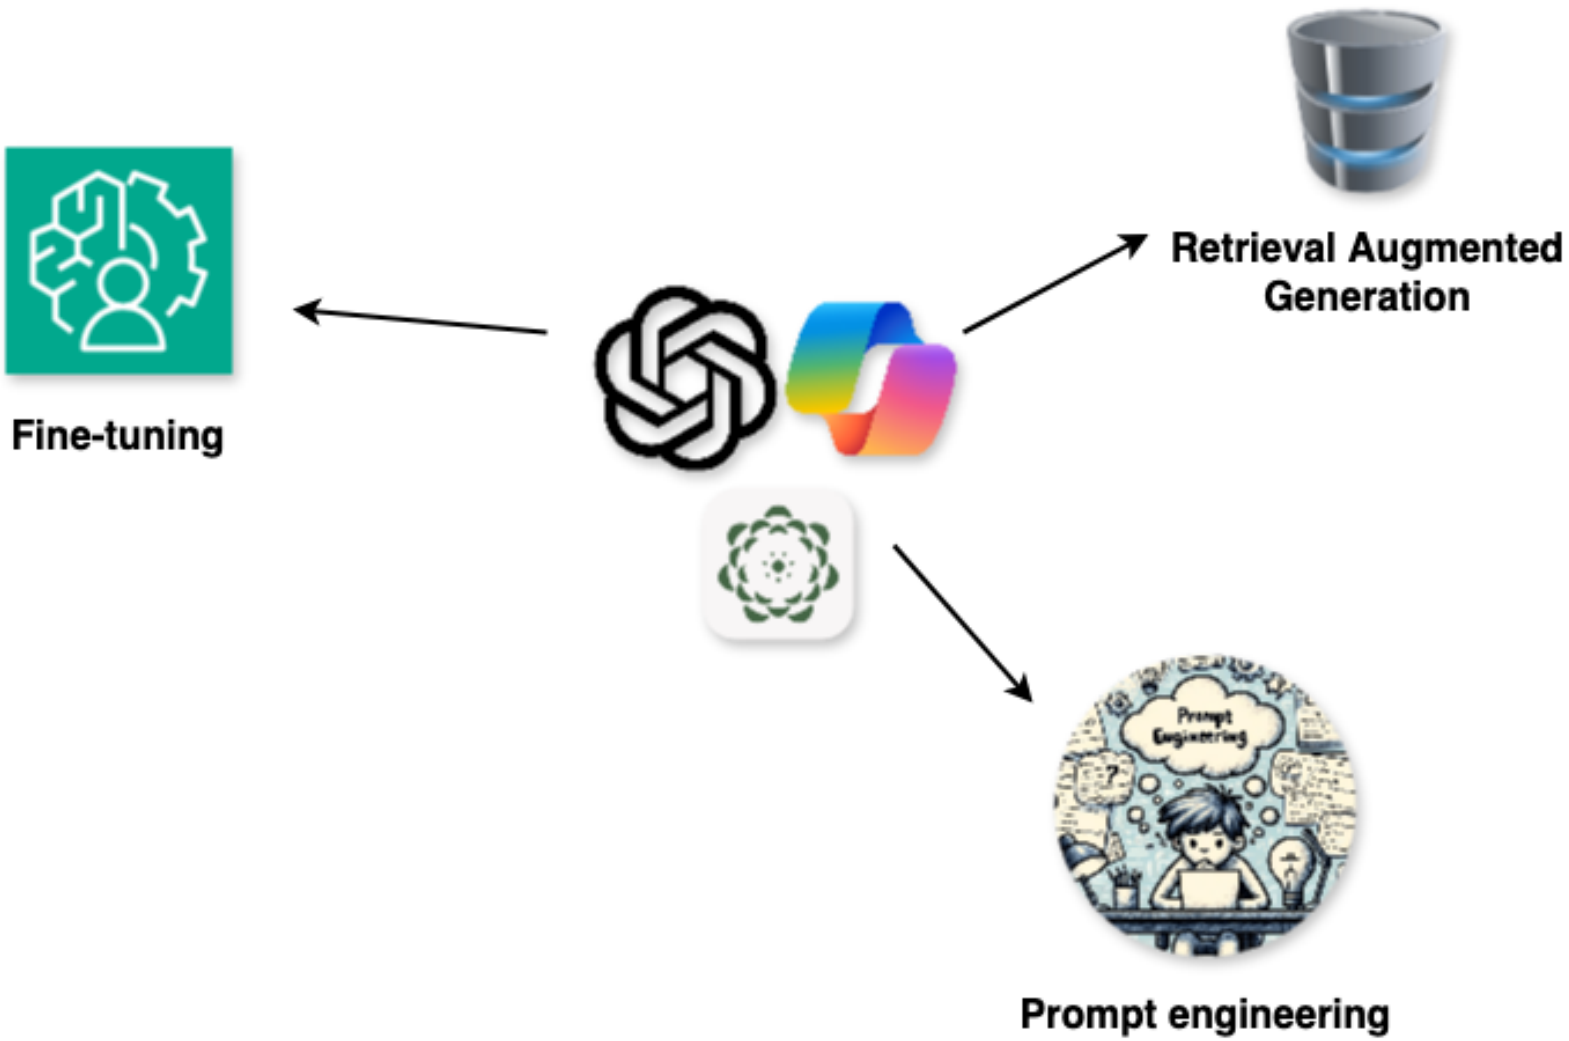
Fine-tuning
Retrieval Augmented Generation
Prompt engineering

Merci pour votre attention

scai

SORBONNE CLUSTER FOR
ARTIFICIAL INTELLIGENCE